INFORME TÉCNICO

# Informe Técnico de Datos

## y Bitácora de Tratamiento (Pipeline ETL)

---

## GastronomIA

**Proyecto:** GastronomIA — Asistente Conversacional Gastronómico

**Materia:** Aproximación al Campo Laboral

**Volumen final del dataset:** 8.181 establecimientos gastronómicos únicos (CABA y GBA)

**Fuentes integradas:** OpenStreetMap (API Overpass) + Buenos Aires Data (Gobierno CABA)

## 1. Resumen Ejecutivo y Alcance del Dataset

El objetivo de este proceso de ingeniería de datos consistió en consolidar una base de datos unificada, geolocalizada y enriquecida sobre comercios gastronómicos en la Ciudad Autónoma de Buenos Aires (CABA) y el primer cordón del Gran Buenos Aires (GBA). Esta base sirve como la capa de persistencia primaria para el asistente inteligente GastronomIA.

Frente a la escasez de etiquetado estructurado público sobre restricciones alimentarias (menús aptos para celíacos/Sin TACC, veganos y vegetarianos), se diseñó un flujo de trabajo que combina datos oficiales habilitados, datos comunitarios georreferenciados, técnicas de inferencia léxica y geocodificación inversa automatizada.

| 8.181 | 5.441 | 2.740 | 100% |
|---|---|---|---|
| Establecimientos únicos | OpenStreetMap (66,5%) | BA Data (33,5%) | Cobertura barrio y coordenadas |

## 2. Bitácora Detallada Paso a Paso del Tratamiento de Datos

**1**

### Extracción de Datos Multifuente (Extract)

- OpenStreetMap (OSM): mediante la API Overpass QL y un Bounding Box delimitado para CABA y GBA, se extrajeron 5.441 nodos y vías catalogados bajo la categoría amenity (restaurantes, bares, cafés, pizzerías, comida rápida). Se obtuvieron coordenadas GPS (latitud/longitud), nombres, etiquetas comunitarias de cocina y contacto.
- Buenos Aires Data (BA Data): se integró la base oficial de establecimientos gastronómicos habilitados de CABA (Agencia Gubernamental de Control / ENTUR), aportando 2.740 registros con direcciones formales, rubro habilitado, teléfono, correo electrónico y barrio.

**2**

### Estandarización de Esquema y Mapeo Homogéneo (Transform - Parte I)

Se unificaron las estructuras de ambas fuentes en un esquema único compuesto por 14 campos estándar:

- *id_origen*, *nombre*, *tipo_establecimiento*, *cocina*, *direccion*, *barrio_localidad*, *telefono*, *website*, *es_vegano*, *es_vegetariano*, *es_sin_tacc*, *latitud*, *longitud*, *fuente_dato*.

**3**

### Algoritmo de Inferencia Léxica de Menús y Reglas de Seguridad

Se constató cuantitativamente que menos del 2% de los comercios en bases públicas contienen etiquetas estructuradas de aptitud dietaria. Para mitigar esta omisión:

- Se implementó un script en Python para evaluar las cadenas de texto de nombre y cocina buscando patrones clave en español e inglés (***"gluten free"***, ***"sin tacc"***, ***"plant based"***, ***"vegano"***, ***"saludable"***).
- Los registros con coincidencias fueron reetiquetados como **Apto / Con opciones (Inferido)**.
- Por política estricta de seguridad y prevención de riesgos para la salud, todo registro sin dato explícito ni inferido se mantuvo como **Sin datos (Confirmar con el local)**.

**4**

### Geocodificación Inversa (Reverse Geocoding)

Para resolver el problema de 2.982 nodos de OSM que contaban con coordenadas geográficas precisas pero carecían de dirección o barrio escrito:

- Se integró la librería **Geopy** con el motor **Nominatim**.
- Se ejecutó un proceso batch que convirtió los pares de latitud y longitud en nombres de calle, altura catastral y barrio/municipio oficial.
- Se logró un **100% de cobertura** en la variable barrio_localidad.

**5**

### Desduplicación por Criterio Combinado

- Se aplicó un filtro de unicidad sobre la clave compuesta *[nombre + barrio_localidad]*, eliminando redundancias entre los registros del gobierno y los de OpenStreetMap, obteniendo una cifra final de **8.181 establecimientos gastronómicos únicos**.

**6**

### Saneamiento de Encoding (Mojibake) y Normalización de Coordenadas

En el control de calidad final del dataset:

- Se corrigió la falla de codificación de caracteres especiales (ej. *"Juan MarÃa GutiÃ©rrez"* a ***"Juan María Gutiérrez"***) re-codificando los bytes de latin1 a utf-8.
- Se ajustó la escala decimal de las coordenadas geográficas que habían perdido la coma flotante durante las exportaciones intermedias.
- Se unificaron las etiquetas redundantes de inferencia para garantizar coherencia en las consultas SQL/Pandas del chatbot.

## 3. Diccionario de Datos del Dataset Consolidado

| Campo | Tipo de Dato | Descripción | Ejemplo |
|---|---|---|---|
| id_origen | String / BigInt | Identificador único asignado en la fuente de origen. | 247463215 |
| nombre | String | Nombre comercial del establecimiento gastronómico. | Restaurant Museo Evita |
| tipo_establecimiento | String | Categoría comercial (restaurante, bar, café, fast_food). | restaurant |
| cocina | String | Especialidad o tipo de cocina reportado. | italian, pizza |
| direccion | String | Nombre de la calle y altura catastral (si está disponible). | Juan María Gutiérrez 3926 |
| barrio_localidad | String | Barrio oficial de CABA o Municipio del GBA. | Palermo |
| telefono | String | Número de contacto telefónico para confirmación del usuario. | 011 4800-XXXX |
| website | String | Sitio web, red social o correo electrónico de contacto. | https://www.museoevitaresto.com.ar/ |
| es_vegano | String | Clasificación (Apto / Sin datos / Inferido / No disponible). | Sin datos (Confirmar con el local) |
| es_vegetariano | String | Clasificación (Apto / Sin datos / Inferido / No disponible). | Apto / Con opciones |
| es_sin_tacc | String | Clasificación (Apto / Sin datos / Inferido). | Sin datos (Confirmar con el local) |
| latitud | Float | Coordenada de latitud en formato decimal. | -34.5805799 |
| longitud | Float | Coordenada de longitud en formato decimal. | -58.4149412 |
| fuente_dato | String | Origen de la extracción (OpenStreetMap / BA Data). | OpenStreetMap |

## 4. Métricas Finales del Dataset

- Total de registros gastronómicos únicos: **8.181**
- Registros provenientes de OpenStreetMap: **5.441 (66.5%)**
- Registros provenientes de BA Data (Gobierno CABA): **2.740 (33.5%)**
- Cobertura de Barrio / Localidad: **100%**
- Cobertura de Coordenadas (Lat/Lon): **100%**

## 5. Conclusión y Estrategia de Mitigación en el Asistente Conversacional

El análisis cuantitativo del dataset demuestra que la gran mayoría de los establecimientos carecen de validación oficial en origen respecto a dietas especiales. Lejos de constituir una limitación, esta situación valida la arquitectura planteada para **GastronomIA**:

El asistente actúa como un motor de búsqueda y recomendación geolocalizado que centraliza la oferta y provee los datos de contacto directo (teléfono/web) de cada comercio. Por diseño en el *System Prompt*, el LLM tiene la instrucción explícita de aclarar que las opciones mostradas son recomendaciones basadas en registro y sugerir siempre al usuario la llamada o contacto previo para verificar ingredientes y protocolos de contaminación cruzada.

> ⚠️ **NOTA DE SEGURIDAD ALIMENTARIA**
> Toda recomendación del asistente debe ir acompañada de la sugerencia de confirmar con el local ingredientes y protocolos de contaminación cruzada antes de consumir.